

PROJE RAPORU

LLM Sub-Agent'larında Rol Mühendisliği ve Değerlendirme Tutarlılığı:

Feature Selection Çalışması

Hazırlayan: Osman

Tarih: 10 Haziran 2026

LLM: Claude Opus 4.6 (Anthropic)

Arayuz: Claude Desktop (lokal session)

ICINDEKILER

ICINDEKILER	2
1. GIRIS VE MOTIVASYON	4
1.1 Projenin Kapsami	4
1.2 Kullanilan Teknolojiler ve Araclar	4
2. METODOLOJI	5
2.1 Agent Tasarimi ve Prompt Yapisi	5
2.2 Agent Gruplari	5
2.3 Ground Truth (Referans Degerlendirme)	5
2.4 Degerlendirilen 30 Ozellik (6 Kategori)	5
3. VERI AKISI VE TABLOLAR	7
3.1 Uretilen Tablolar	7
Tablo 1 -- Agent Puanlari (table1_agent_scores)	7
Tablo 2 -- Agent Metadata (table2_agent_metadata)	7
Tablo 2 Normalized -- Normalize Metadata	7
Tablo 3 -- Oznitelik Skorlari (table3_agent_oznitelik_score)	7
3.2 Normalizasyon Sureci	7
3.3 Oznitelik Skoru Formulu	7
4. BULGULAR VE ANALIZ	9
4.1 Bireysel Agent Incelemesi: Google Staff UX Engineer	9
4.2 Genel Oznitelik Istatistikleri	10
4.3 En Yuksek ve En Dusuk Ozellikler (100 Agent Ortalamasi)	10
4.4 Degerlendiremem (98) Analizi	11
5. GRUP BAZLI PERFORMANS VE EN BASARILI AGENTLER	12
5.1 Grup Karsilastirmasi	12
Temel Cikarimlar	12
5.2 Grup Birincileri -- Radar Profilleri	13
5.3 Grup Birincileri -- Ozellik Bazli Detay	13
6. PROJE ADIMLARI VE SUREC	15
6.1 Planlama ve Hazirlik	15
6.2 Prompt Muhendisligi	15
6.3 Veri Toplama	15
6.4 Veri Isleme ve Tablo Uretimi	15
6.5 Gorsellestirme ve Raporlama	15
7. TARTISMA	16
7.1 Rol Taniminin Etkisi	16
7.2 Prompt Kalitesi ve Oznitelik Iliskisi	16

7.3 Gorsel vs. Teknik Ozellikler	16
7.4 Sinirliliklar	16
8. SONUC	17
8.1 Gelecek Calismalar	17
9. PROJE DOSYA YAPISI	18

1. GIRIS VE MOTIVASYON

Bu proje, **buyuk dil modellerinin (LLM) rol-bazli sub-agent'lar olarak kullanildiginda degerlendirme tutarlilikini ve performansini** sistematik olarak olcmeyi amaclamaktadir. Claude Opus 4.6 modeli uzerinde 100 farkli rol-bazli persona olusturulmus, her persona ayni frontend projesini 30 kalite ozelligi uzerinden degerlendirmistir.

Temel arastirma sorusu: Bir LLM'e verilen rol prompt'unun yapisi, detay duzeyi ve alan uzmanligi tanimi, modelin degerlendirme kalitesini nasil etkiler?

1.1 Projenin Kapsami

- 100 farkli rol-bazli sub-agent (persona) olusturuldu
- Her agent, ayni frontend projesini (screenshots + description + features.json) 30 ozellik uzerinden puanladi
- 2 uzman (Ground Truth) degerlendirmesi referans olarak kullanildi
- Sapma analizi + oznitelik skorlama ile agentlerin guclu/zayif yanlari belirlendi

1.2 Kullanilan Teknolojiler ve Araclar

LLM: Claude Opus 4.6 (Anthropic) -- temperature=0 ile deterministik cikti

Calistirma Yontemi: Claude Desktop uygulamasini uzerinden lokal session'da tek tek prompt verilerek anket cozdurulen dongu ile gerceklestirildi. API secenegi mevcut olmasina ragmen maliyet nedeniyle tercih edilmedi.

Veri Isleme: Python (CSV, JSON, Excel uretimi)

Gorsellestirme: HTML/CSS/Canvas dashboard, matplotlib

Onemli Not: Her agent izole ve stateless calistirildi -- persona bleed (rol karisimi) engellendi.

2. METODOLOJİ

2.1 Agent Tasarimi ve Prompt Yapisi

Her agent için yapılandırılmış bir prompt .md dosyası oluşturulmuştur. Tüm promptlar 7 standart bölüm içerir:

1. **ROLE** -- Agentin rolü, şirketi, deneyim yılı ve uzmanlık alanı
2. **CONTEXT** -- Değerlendirme bağlamı, projenin ne olduğu
3. **CAPABILITIES** -- Agentin teknik yetenekleri ve uzmanlık alanları
4. **TASK APPROACH** -- Değerlendirme yaklaşımı, adım adım yöntem
5. **RULES** -- Puanlama kuralları ve kısıtlamalar
6. **CONSTRAINTS** -- Yasaklar ve sınırlamalar
7. **OUTPUT FORMAT** -- Çıktı formatı (JSON)

Prompt uzunlukları: **min=1.357, max=4.238, ortalama=2.040 karakter** (kelime: min=223, max=605, ort=315).

2.2 Agent Grupları

100 agent, prompt yapısına göre 4 gruba ayrılmıştır:

Grup	Tanım	Sayı	ID Aralığı ve Açıklama
A	BigTech + Departman	25	001-025: Şirket + departman + rol (Google, Microsoft vb.)
B	Sadece Şirket	25	026-050: Şirket + rol, departman yok (Vercel, Stripe vb.)
C	Bagimsiz/Teknik	40	051-090: Şirketsiz teknik uzman, akademisyen, öğrenci
D	Teknik-Disi Kontrol	10	091-100: Teknik bilgisi olmayan roller (muhasebeci vb.)

2.3 Ground Truth (Referans Değerlendirme)

İki farklı uzman değerlendirmesi Ground Truth olarak kullanılmıştır:

Admin	Tur	Ortalama	Puanlanan	98 (N/A)
Gemini Pro 3.1	AI (Google)	8.7	28/30	2
Osman	İnsan Uzman	7.2	29/30	1

Her özellik için iki adminin ortalaması alınarak Expert Average oluşturulmuştur.

2.4 Değerlendirilen 30 Özellik (6 Kategori)

VISUAL: UI, UX, Visual Design, Typography, Animation, Theming

CODE: Code Quality, Component Architecture, State Management, Reusability, Maintainability

INFRA: Performance, Security, Error Handling, API Integration, Scalability

UX/FUNC: Functionality, Form Validation, Navigation, Loading States, Empty States

DOMAIN: Domain Knowledge, Consistency, Innovation, Documentation

TECH: Responsive Design, Accessibility, Data Structures, Testing

3. VERİ AKISI VE TABLOLAR

3.1 Üretilen Tablolar

Projede 4 ana tablo üretilmiştir. Her biri bir öncekinin üzerine inşa edilir:

Tablo 1 -- Agent Puanlari (table1_agent_scores)

103 satir x 32 sutun: 2 admin + 1 deneme + 100 agent. Her satirda agent_id, agent_name ve 30 ozellik puani (1-10 arasi tam sayi veya 98='degerlendiremem'). Admin satirlari Excel'de sari vurgulu.

Tablo 2 -- Agent Metadata (table2_agent_metadata)

101 satir x 25 sutun: Manuel alanlar (role_title, company, department, boolean flagler, company_tier, seniority_level, experience_years) ve prompt .md dosyasindan otomatik turetilen alanlar (prompt_length, word_count, 7 bolum sayisi).

Tablo 2 Normalized -- Normalize Metadata


101 satir x 23 sutun: Sayisal sutunlar 1-10 arasina min-max normalize edildi. Boolean'lar korundu (True/False). Son sutun: prompt_avg_point = sayisal normalize sutunlarin ortalamasi (min=2.3, max=8.8, ort=4.8).

Tablo 3 -- Oznitelik Skorlari (table3_agent_oznitelik_score)

100 satir x 32 sutun: Her agent icin yuzdelik oznitelik skoru (min=%16.2, max=%63.1, ort=%34.7). Completeness sutunu tum agentlerde N/A oldugu icin drop edilmistir.

3.2 Normalizasyon Sureci

Tablo 2'deki sayisal metadata alanlari asagidaki formulle 1-10 arasina normalize edilmistir:



Sekil 1: Normalizasyon sureci -- Raw metadata'dan normalize tabloya gecis

3.3 Oznitelik Skoru Formulu

Tablo 3'teki yuzdelik oznitelik skorlari asagidaki formulle hesaplanmistir. Formül, agentin ham puanini hem prompt kalitesiyle hem de uzman referansiyla agirliklandirir:



Sekil 2: Oznitelik skoru formulu -- Ornek: Agent UI=8, Prompt_Avg=7.7, Admin_UI_Avg=7.5 ise oznitelik = %82.1


4. BULGULAR VE ANALIZ

4.1 Bireysel Agent Incelemesi: Google Staff UX Engineer


Bulgulari somutlastirmek icin once tek bir agenti detayli inceleyelim. Grup A birincisi olan 004_google_staff_ux_eng agenti:

Google Staff UX Engineer — Grup A Birincisi | Overall: %63.1

Prompt Avg: 7.7 | Mean Raw Score: 6.4 | 29 Ozellik Puanlandi



Sekil 3a: Google Staff UX Engineer -- Kategori bazli radar profili



Sekil 3b: Google Staff UX Engineer -- 29 ozellik oznitelik skorlari

Gozlemler: Bu agent, Visual kategorisinde en guclu (%75.7) -- Google Material Design deneyimi, gorsel ozelliklerde yuksek hassasiyet saglamistir. Theming (%86.6) ve UI (%82.1) en yuksek oznitelik skorlari. Buna karsilik Empty States (%33.0) ve Error Handling (%41.1) en zayif alanlar -- bunlar screenshot'lardan degerlendirmesi en zor ozelliklerdir.


Bu patern diger agentlerde de tekrarlanmaktadır: gorsel ozellikler yuksek, teknik/gizli ozellikler dusuk.

4.2 Genel Oznitelik Istatistikleri

100 agent uzerinden ortalama oznitelik skoru: **%34.7** (min: %16.2, max: %63.1). Agentler ortalamada uzman referansinin yaklasik ucte biri kadar isabetli degerlendirme yapmistir.

4.3 En Yuksek ve En Dusuk Ozellikler (100 Agent Ortalamasi)

Asagidaki grafik, tum agentlerin ortalama oznitelik skorlarina gore en basarili ve en zayif 5 ozelligi gostermektedir:




Sekil 4: Tum agentlerin ortalama oznitelik skorlarına göre en yuksek ve en dusuk 5 ozellik

Yorum: Theming, Performance ve Loading States gibi screenshot'lardan dogrudan gorulebilir ozellikler en yuksek; Empty States, Error Handling ve Documentation gibi gizli/soyut ozellikler en dusuk skor almistir.

4.4 Degerlendiremem (98) Analizi

98 kodu, agentin ilgili ozelligi degerlendiremedigini ifade eder. Asagidaki grafik, her ozellik icin kac agentin 98 verdigini gosterir:




Sekil 5: Ozellik bazinda 98 (degerlendiremem) veren agent sayisi

Testing, Scalability ve Data Structures gibi **teknik/kod tabanlı özellikler** en yuksek 98 oranına sahiptir. Özellikle Grup D (teknik-disi) agentlerinin neredeyse tamamı bu alanlarda 98 vermiş -- rol taniminin modeli kendi uzmanlık sinirlarini dogru tanimaya yonlendirdigi gorulmektedir.

5. GRUP BAZLI PERFORMANS VE EN BASARILI AGENTLER

5.1 Grup Karsilastirmasi

Asagidaki grafik, 4 grubun ortalama oznitelik skorlarini, min-max araliklarini ve grup birincilerini gostermektedir:



Sekil 6: Grup bazli performans karsilastirmasi (bar: ortalama, cizgi: min-max, yildiz: birinci)

Grup	Birinci	Ort.	Min	Max	Pr.Avg	N
A	Google Staff UX Eng	%46.0	%36.5	%63.1	7.7	25
B	Vercel Fullstack Dev	%34.7	%25.2	%50.6	6.3	25
C	HCI Professor	%30.1	%18.1	%59.9	8.8	40
D	Accountant (Kontrol)	%25.2	%16.2	%47.1	6.6	10

Temel Cikarimlar

- Grup A (BigTech+Dept) en yuksek ortalamaya sahiptir (%46.0). Sirket + departman + rol uclusu, modelin degerlendirme kalitesini artirmaktadir.
- Grup C'de HCI Profesoru (%59.9) tek basina gruptan cok yuksek cikmistir -- en yuksek prompt_avg (8.8) ve detayli akademik yaklasim.
- Grup D (teknik-disi kontrol) beklendigi gibi en dusuk performansi gostermistir (%25.2 ort).
- Grup B, A'ya gore dusuktur. Departman bilgisi eksikligi, modelin rolu dar yorumlamasına yol acmis olabilir.

5.2 Grup Birincileri -- Radar Profilleri


Asagidaki radar grafikleri, her grubun birincisinin 6 kategorideki oznitelik dagilimini gostermektedir:



Sekil 7: 4 grup birincisinin radar profilleri (VIS=Visual, CODE=Code, INFRA=Infrastructure, UX/F=UX/Func, DOM=Domain, TECH=Tech)

5.3 Grup Birincileri -- Ozellik Bazli Detay

Her grup birincisinin 29 ozellikteki oznitelik skorlari:



Sekil 8: 4 grup birincisinin tum ozellik oznitelik skorlari. Grup D'de 16 ozellik N/A (98).

Grup A - Google Staff UX Eng (%63.1): Visual kategorisinde baskin (%75.7). Theming (%86.6) en guclu. Code ve Infra dengeli.

Grup B - Vercel Fullstack Dev (%50.6): Performance odakli profil. Theming (%70.9) ve Performance (%67.8) ust siralarda. Domain Knowledge (%31.5) zayif.

Grup C - HCI Professor (%59.9): En yuksek prompt_avg (8.8) ama en dusuk mean raw (5.3). Titiz ama dusuk puanlama egilimi. Consistency (%88.0) cok guclu.

Grup D - Accountant (%47.1): Sadece 13 ozellik puanlandi. Gorsel ozellikler %57-62 arasi. 16 teknik ozellik 98 -- kontrol grubu davranisi basarili.

6. PROJE ADIMLARI VE SUREC

6.1 Planlama ve Hazirlik

1. Projenin basligi ve kapsamı belirlendi
2. Degerlendirilecek frontend projesi secildi ve input paketi hazirlandi
3. 30 kalite ozelligi tanimlandi ve 6 kategoriye ayrildi
4. Agent gruplari tasarlandi (A/B/C/D)

6.2 Prompt Muhendisligi

1. 100 adet yapilandirilmis prompt .md dosyasi yazildi
2. Her prompt 7 standart bolum icerecek sekilde yapilandirildi
3. Farkli sirket, departman, kidem duzeyi ve uzmanlik alanlari ile cesitlilik saglandi
4. Prompt metadata otomatik olarak parse edildi (build_metadata.py)

6.3 Veri Toplama

1. Ground Truth: Iki admin (Gemini Pro 3.1 + Osman) projeyi bagimsiz degerlendirdi
2. 100 agent Claude Desktop uygulamasinda sirayla calistirildi (temperature=0, izole session)
3. Her agentin ciktilisi JSON olarak kaydedildi (anket/ klasoru)

6.4 Veri Isleme ve Tablo Uretimi

1. Tablo 1: Ham puanlar -> CSV + Excel
2. Tablo 2: Prompt metadata -> CSV + Excel (25 sutun)
3. Tablo 2 Normalized: Sayisal alanlar 1-10 normalize + prompt_avg_point
4. Tablo 3: Oznitelik skorlari = $(\text{puan} \times \text{prompt_avg}) / (\text{admin_avg} \times 10) \times 100$

6.5 Gorsellestirme ve Raporlama

- Matplotlib ile ilk FIFA-tarzi agent karti uretildi (PNG)
- HTML/CSS/Canvas dashboard'a gecildi -- profil, radar, prompt, feature bars, siralama
- 4 grup sekmesi (navbar) ile her grubun en basarilisi tek dashboard'da toplandi
- Word (.docx) + PDF formatinda kapsamli proje raporu hazirlandi

7. TARTISMA

7.1 Rol Taniminin Etkisi

- Sirket + departman + rol uclusu (Grup A) en yuksek ortalama oznitelik skorunu uretmistir (%46.0).
- Yalnizca sirket + rol (Grup B) belirgin bir dusus gostermistir (%34.7). Departman bilgisi, modelin uzmanlik alanini daha iyi daraltmasina yardimci olmaktadır.
- Teknik-disi roller (Grup D) beklendigi gibi en dusuk performansi gosteremis, ancak kendi uzmanlik sinirlarini dogru tanimistir (yuksek 98 orani).

7.2 Prompt Kalitesi ve Oznitelik Iliskisi

HCI Profesoru ornegi dikkat cekicidir: Dusuk mean raw score (5.3) ama en yuksek prompt_avg (8.8). Model, yuksek kaliteli bir prompt'la daha titiz ama potansiyel olarak daha dusuk puanlama egilimi gostermektedir. Oznitelik formulu bu dengeyi yakalamaktadır.

7.3 Gorsel vs. Teknik Ozellikler

Gorsel ozellikler (Theming, UI, Visual Design) tum grupta yuksek puanlanmistir -- screenshot'lardan dogrudan gorulebilir olmalari nedeniyle. Teknik ozellikler (Testing, Scalability) ise en yuksek 98 oranlarina sahiptir.

7.4 Sinirlilikler

- Tum agentler tek bir LLM (Claude Opus 4.6) uzerinde calistirilmistir.
- Ground Truth 2 uzman (1 AI + 1 insan) ortalamasidir. Daha fazla uzman ile inter-rater reliability analizi yapilamistir.
- Degerlendirme yalnizca screenshot + description temelli yapilmistir.
- temperature=0 kullanilmis olsa da, model ciktilarinda kucuk varyasyonlar mumkundur.

8. SONUC

Bu calisma, LLM sub-agent'larinda rol muhendisliginin degerlendirme kalitesi uzerindeki etkisini sistematik olarak ortaya koymustur:

5. Sirket + departman + rol uclusu (Grup A), en yuksek ve en tutarli degerlendirme performansini saglamistir.
6. Prompt kalitesi (bolum sayisi, detay duzeyi) puan kalitesiyle dogrudan iliskilidir.
7. Teknik-disi roller, kendi uzmanlik sinirlarini dogru tanimis (98 kullanimi), bu da rol prompt'unun modeli kalibre ettigini gosterir.
8. Gorsel ozellikler tum grupta teknik ozelliklerden daha yuksek puanlanmistir.
9. Oznitelik formulu, prompt kalitesini ve uzman referansini birlikte degerlendiren etkili bir metrik olarak calismistir.

8.1 Gelecek Calismalar

- Feature Selection algoritmaları (Random Forest, LASSO, PCA) ile istatistiksel analiz
- Farklı LLM'ler (GPT-4, Gemini, Llama) ile karsilastirmali calisma
- Daha fazla uzman degerlendirmesi ile inter-rater reliability analizi
- Canli uygulama testi dahil edilerek degerlendirme kapsamının genişletilmesi
- Prompt optimizasyonu: En basarili agentlerin ortak ozelliklerinden ideal prompt sablonu cikarilmasi

9. PROJE DOSYA YAPISI

Dosya / Klasor	Aciklama
prompts/	100 agent prompt .md dosyasi
anket/	Agent JSON ciktilari (puanlar + notlar)
theExaminedProject/	Degerlendirilen proje (screenshots, description, features.json, src/)
tablolar/	Tum CSV ve Excel tablolari
Rapor/	Raporlar, gorseller, dashboard
Rapor/oznitelik html & images/	HTML dashboard (4 sekmeli) ve gorseller
build_metadata.py	Prompt metadata parser
generate_card.py	Matplotlib ile agent karti uretir
CLAUDE.md	Proje talimatlari ve veri akisi